Pandas 1주차 스터디 복습

필수 명령어 정리 및 Palmer Penguins 데이터 분석 실습

Part 1. 데이터 파악 및 선택

데이터를 처음 불러오고 기본적인 구조와 통계량을 파악하는 필수 명령어

데이터 로드 및 기본 정보 파악

1. read_csv()

CSV 파일을 읽어 데이터프레임으로 변환합니다.

```
df =
pd.read_csv('penguins.csv')
df.head(2)
```

```
species island body_mass_g 0
Adelie Torgersen 3750.0 1 Adelie
Torgersen 3800.0
```

2. info()

데이터 타입, 결측치 수 등 전반적인 정보를 확인합니다.

```
df.info()
```

```
RangeIndex: 344 entries Data
columns: 7 columns dtypes:
float64(4), object(3)
```

3. describe()

수치형 데이터의 기술 통계량을 한눈에 확인합니다.

```
df.describe()
```

```
body_mass_g count 342.000000
mean 4201.754386 min 2700.000000
max 6300.000000
```

데이터 선택 (loc vs iloc)

loc: 라벨(이름) 기반 선택

df.loc[행 라벨, 열 라벨] 형태로 인덱스와 컬럼명을 직접 사용하여 데이터를 추출합니다.

```
# 0~2번 인덱스의 species, island 추출 df.loc[0:2, ['species', 'island']]
```

```
species island 0 Adelie Torgersen 1 Adelie Torgersen 2 Adelie Torgersen
```

※ loc에서 슬라이싱 `0:2`는 끝 번호(2)를 **포함**합니다.

iloc: 위치(정수) 기반 선택

df.iloc[행 위치, 열 위치] 형태로 0부터 시작하는 정수형 위치값을 사용하여 데이터를 추출합니다.

```
# 처음 3개 행, 처음 2개 열 추출 df.iloc[0:3, 0:2]
```

```
species island 0 Adelie Torgersen 1 Adelie Torgersen 2 Adelie Torgersen
```

※ iloc에서 슬라이싱 `0:3`은 끝 번호(3)를 **포함하지 않습니다**.

조건 필터링 (불리언 인덱싱)

다중 조건을 사용하여 원하는 데이터만 정확하게 추출할 수 있습니다. **&** **(AND)**, **|** **(OR)** 연산자를 활용할 때는 각 조건을 반드시 괄호로 묶어야 합니다.

다중 조건 필터링 예시

```
# Adelie 종이면서 체중이 4000g 이상인 펭귄 heavy_adelie
= df[ (df['species'] == 'Adelie') &
(df['body_mass_g'] ≥ 4000) ]
print(len(heavy_adelie))
```

```
177
```

위 코드는 내부적으로 True/False로 이루어진 **Boolean Mask**를 생성하여 True인 행만 걸러내는 원리입니다.

Part 2. 전처리 및 집계

결측치를 정제하고 데이터를 그룹화하여 인사이트를 도출하는 필수 명령어

결측치(Missing Values) 처리

isnull().sum()

각 컬럼별로 결측치(NaN)가 몇 개 존재하는지 한눈에 파악할 수 있습니다.

```
df.isnull().sum()
```

```
species 0 bill_length_mm 2
body_mass_g 2 sex 11
```

dropna()

결측치가 하나라도 포함된 행을 삭제합니다.(분석에 치명적인 경우 사용)

```
# sex 컬럼 결측치 행 제거
df.dropna(subset=['sex'])
```

```
원본: 344행 제거 후: 333행
```

fillna()

결측치를 다른 값(평균, 최빈값, 0 등)으로 대체하여 데이터를 보존합니다.

```
# 체중을 평균값으로 대체 avg =
df['body_mass_g'].mean()
df['body_mass_g'].fillna(avg)
```

```
결측치(NaN)가 4201.75로 모두 채워짐
```

그룹화 및 집계 (groupby)

특정 컬럼의 범주(예: 펭귄 종류)를 기준으로 데이터를 그룹화하고, 통계량(평균, 합계 등)을 산출합니다.

```
# 종(species)별 평균 체중(body_mass_g)과 개수(count) 계산 df.groupby('species')['body_mass_g'].agg(['mean', 'count']).round(2)
```

종류 (Species)	평균 체중 (Mean)	데이터 수 (Count)	비고
Adelie	3700.66 g	152 마리	가장 개체수가 많음
Chinstrap	3733.09 g	68 마리	개체수가 가장 적음
Gentoo	**5076.02 g**	124 마리	압도적으로 무거운 체중

정렬과 파생변수 생성

정렬: sort_values()

데이터를 특정 컬럼 기준으로 오름차순(기본) 또는 내림차순 정렬합니다.

```
# 체중 기준 내림차순 정렬
df.sort_values('body_mass_g',
ascending=False).head(3)
```

```
species body_mass_g 237 Gentoo 6300.0 253 Gentoo
6050.0 297 Gentoo 6000.0
```

ascending=False 속성을 주어 값이 큰 순서대로(무거운 펭귄부터) 정렬했습니다.

파생변수 (컬럼 추가)

기존 컬럼의 데이터를 연산하여 새로운 분석 기준이 되는 컬럼을 만듭니다.

```
# g 단위 체중을 kg 단위로 변환
df['body_mass_kg'] = df['body_mass_g'] /
1000 df[['body_mass_g',
'body_mass_kg']].head(2)
```

```
body_mass_g body_mass_kg 0 3750.0 3.75 1 3800.0 3.80
```

새로운 컬럼명 **df['새_이름']**을 선언하고 우변에 계산식을 할당하면 즉시 반영됩니다.

Questions?

1주차 Pandas 복습을 완료하셨습니다. 수고하셨습니다!

Image Sources

https://png.pngtree.com/thumb_back/fw800/background/20260105/pngtree-complex-digital-network-of-interconnected-glowing-nodes-image_21012380.webp

Source: pngtree.com

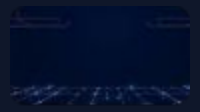

https://png.pngtree.com/thumb_back/fh260/background/20260125/pngtree-futuristic-technology-background-with-glowing-blue-grid-lines-and-nodes-on-image_21219379.webp

Source: pngtree.com