머신러닝 모델 가이드

지도학습, 비지도학습, 차원축소 알고리즘 핵심 요약 및 Sklearn 클래스 맵핑

지도 학습 (Supervised Learning)

정답이 주어진 상태에서 모델을 학습시켜 새로운 데이터를 예측 및 분류합니다.

K-최근접 이웃 (KNN)

가장 가까운 이웃 찾기

새로운 데이터가 들어오면 기존 데이터 중 가장 가까운 K개의 이웃을 찾아 다수결로 분류하거나 평균값으로 예측합니다. 훈련 단계에서 특별한 학습을 수행하지 않고 데이터를 저장하는 특징이 있습니다.

KNeighborsClassifier

KNeighborsRegressor

* 단순하지만 직관적이며 거리 기반의 문제 해결에 매우 효과적입니다.

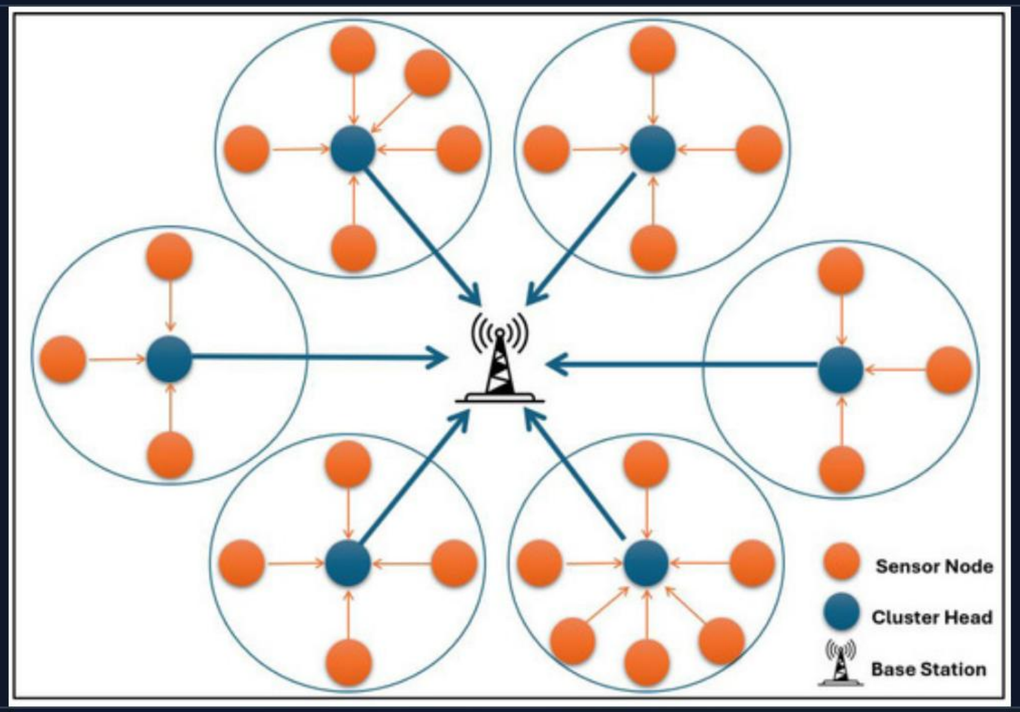

기본 선형 및 확률 모델

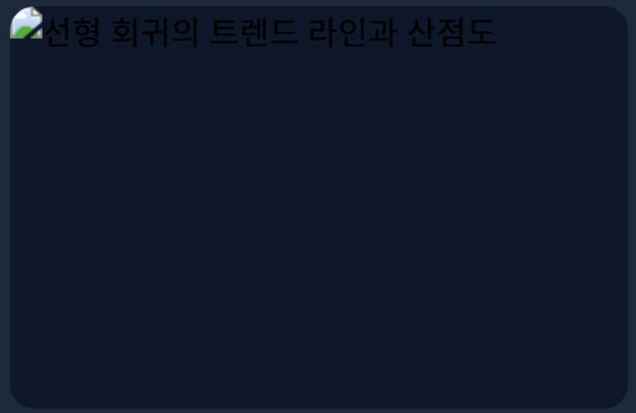

선형 회귀

LinearRegression

데이터 패턴을 가장 잘 설명하는 직선(선형 방정식)을 찾습니다. 연속적인 값(집값 등)을 예측할 때 사용되는 기본 회귀 모델입니다.

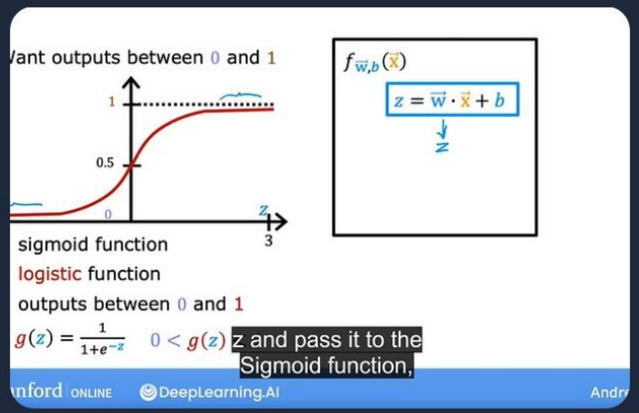

로지스틱 회귀

LogisticRegression

이름은 회귀지만 실제로는 분류 모델입니다. 데이터가 특정 클래스에 속할 확률을 0과 1 사이의 값(시그모이드 함수)으로 예측합니다.

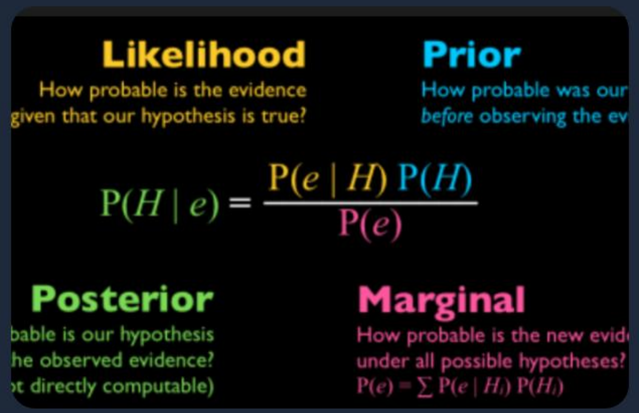

나이브 베이즈

GaussianNB / MultinomialNB

각 특성이 독립적이라는 가정하에, 베이즈 정리를 이용해 확률을 계산하여 분류합니다. 텍스트 분류에 강합니다.

의사결정나무 (Decision Tree)

질문 기반의 규칙 학습

스무고개 하듯이 질문(규칙)을 계속 던져 데이터를 분류하거나 값을 예측하는 모델입니다. 내부 작동 원리가 인간의 사고 방식과 유사합니다.

DecisionTreeClassifier | DecisionTreeRegressor

모델의 추론 과정을 시각화(Tree Graph)하기 쉬워 결과에 대한 설명력(Interpretability)이 매우 뛰어난 것이 큰 장점입니다.

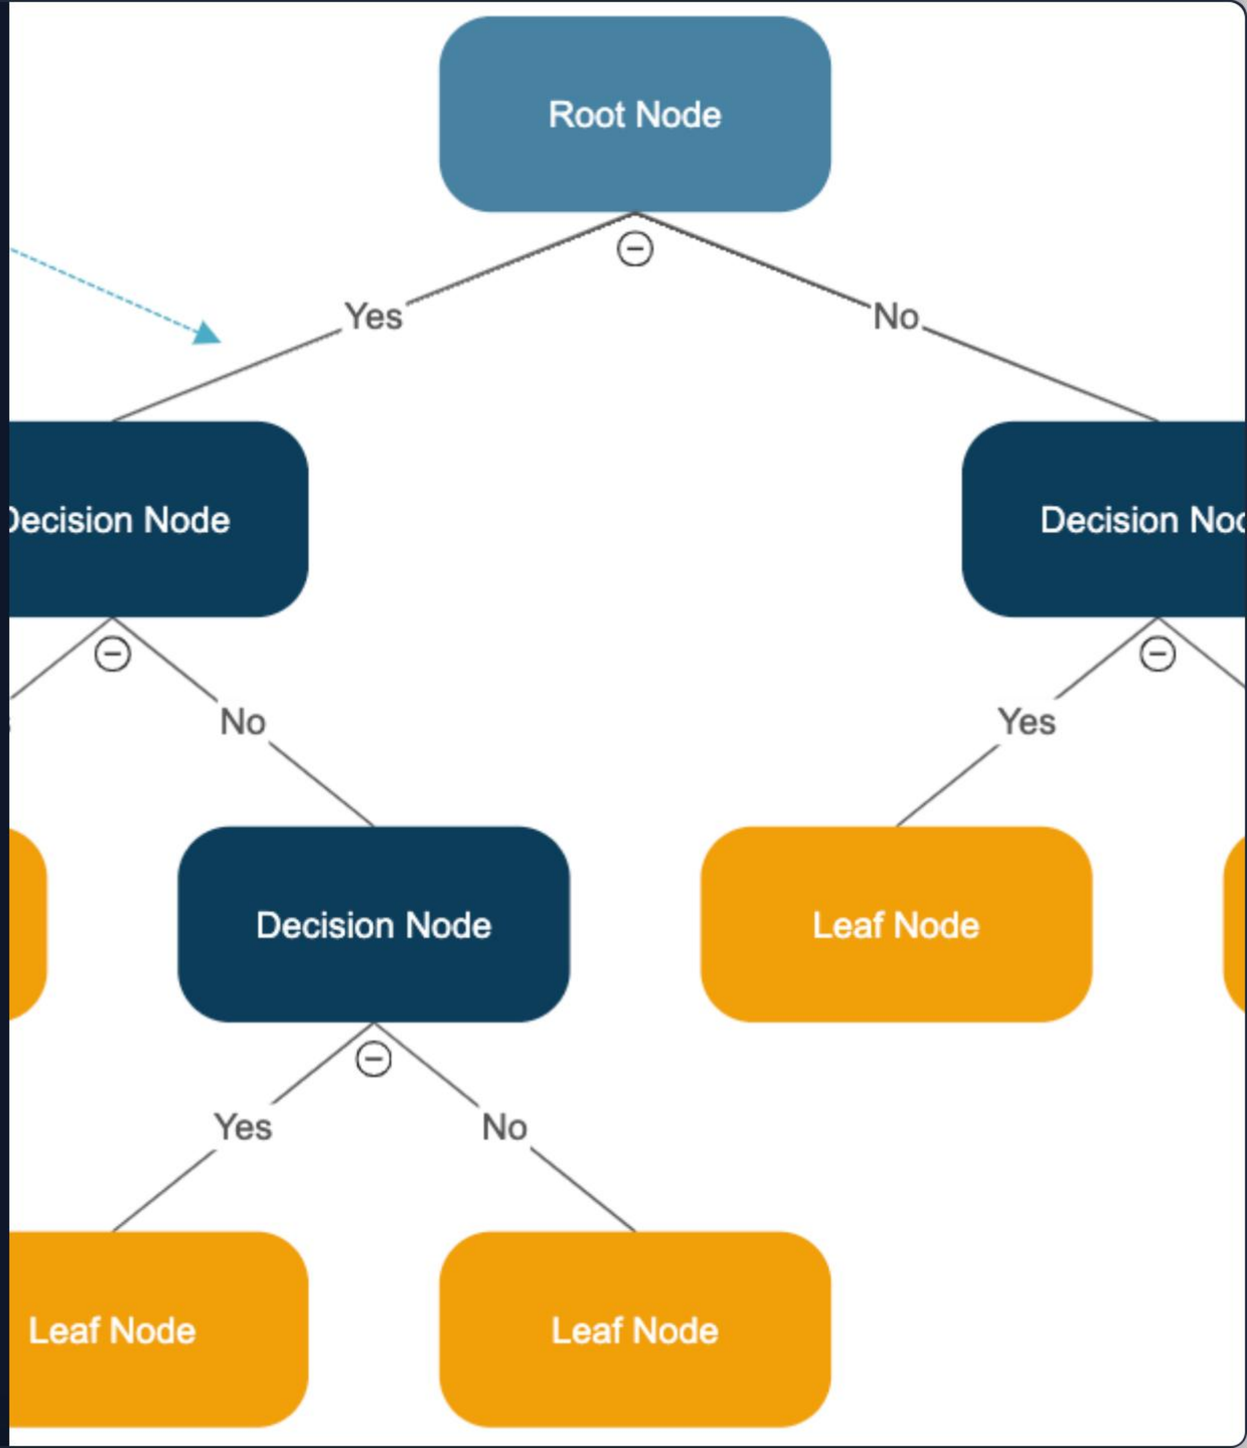

서포트 벡터 머신 (SVM)

마진(Margin)의 최대화

데이터 클래스를 나누는 가장 넓은 도로(결정 경계, Hyperplane)를 찾는 알고리즘입니다. 도로의 폭을 뜻하는 마진(Margin)을 최대화하는 것이 핵심 목표입니다.

SVC (분류) SVR (회귀)

고차원 데이터나 비선형 분류(커널 트릭 사용)에서도 높은 성능을 발휘하며, 이상치에 비교적 덜 민감한 견고한 모델입니다.

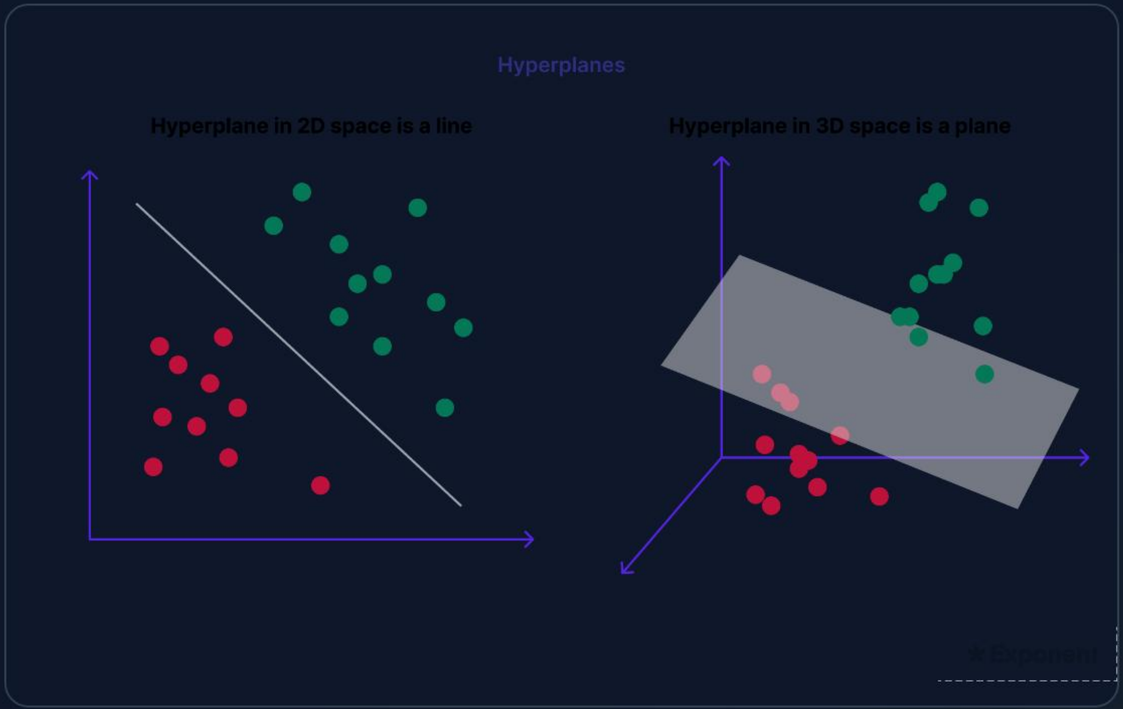

앙상블 (Ensemble)

집단 지성의 힘

여러 개의 모델(주로 결정 트리)을 합쳐서 단일 모델보다 훨씬 더 강력하고 안정적인 예측 모델을 만드는 기법입니다.

RandomForestClassifier

GradientBoostingClassifier

나무(결정 트리)가 모여 숲(랜덤 포레스트)을 이루듯, 약한 학습기들을 결합하여 과적합을 방지하고 일반화 성능을 극대화합니다.

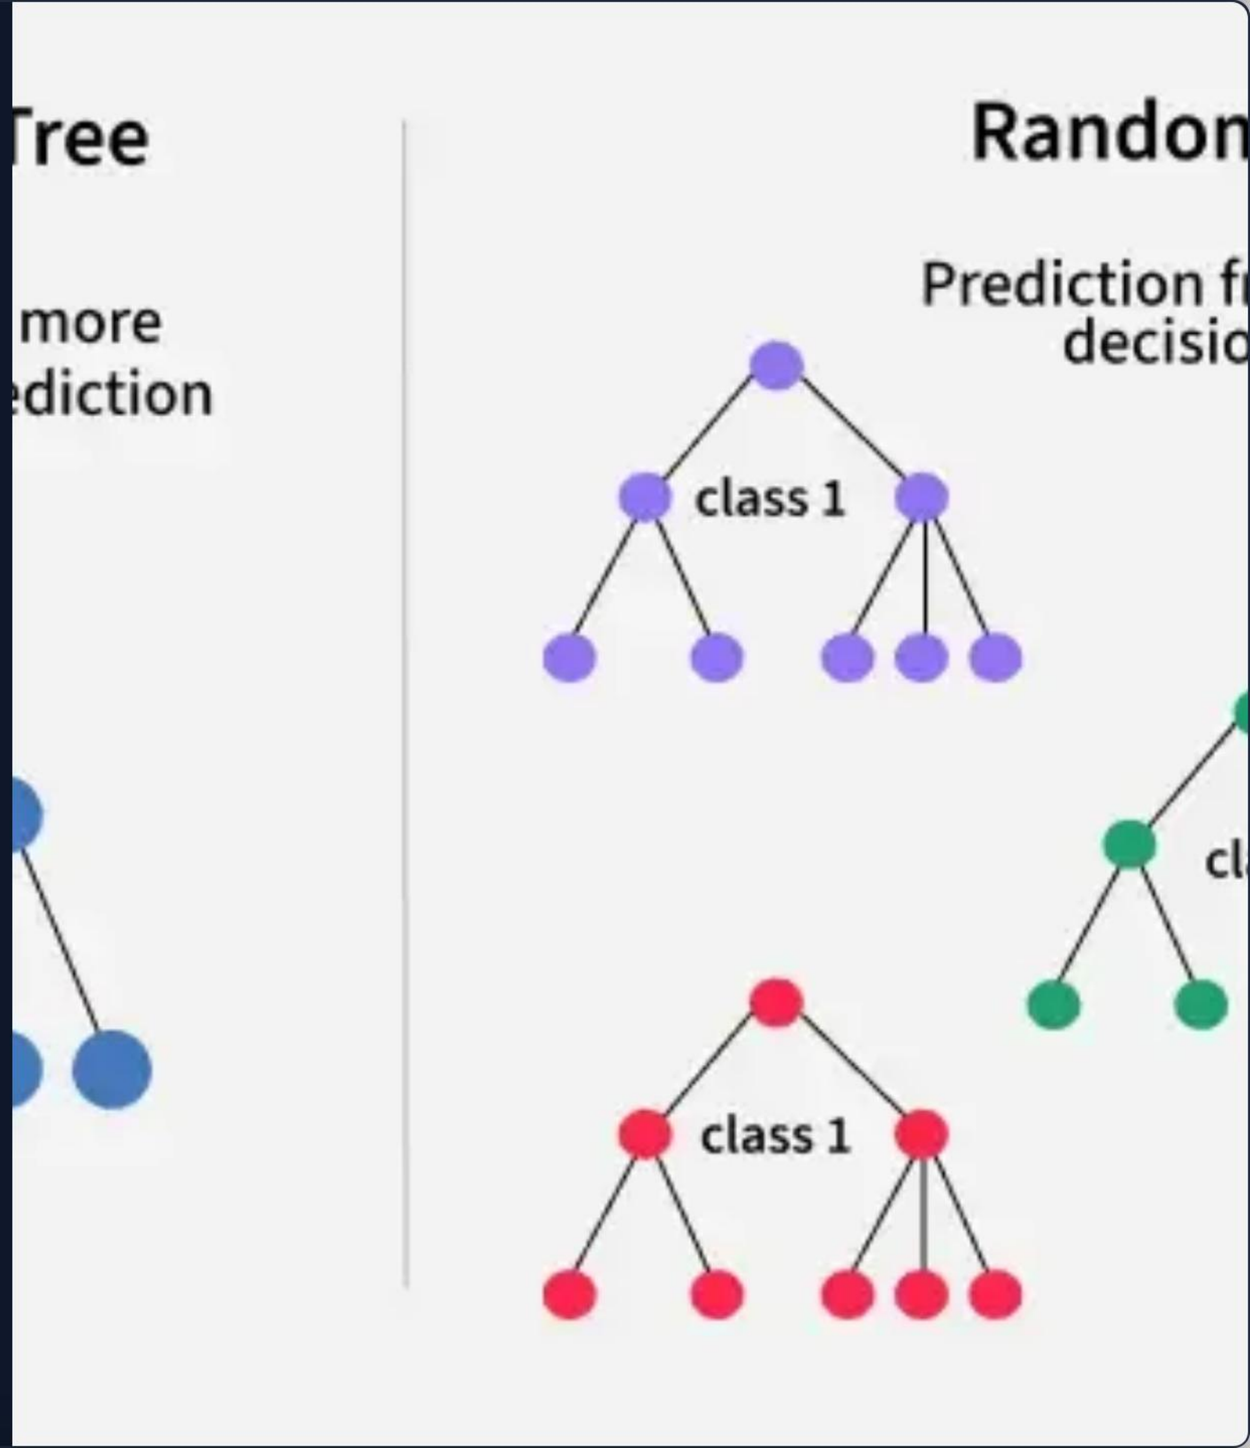

비지도 학습 (Clustering)

정답(Label)이 없는 데이터의 숨겨진 구조와 군집 패턴을 자동으로 찾아냅니다.

K-Means Clustering

중심점 기반 군집화

전체 데이터를 사전에 정의된 K개의 그룹으로 묶습니다. 각 그룹의 중심점(Centroid)을 지속적으로 업데이트하며 최적의 구역을 찾아갑니다.

KMeans

알고리즘이 단순하고 속도가 빨라 대용량 데이터에 널리 쓰이나, 구형(원형)이 아닌 복잡한 형태의 데이터 군집에는 성능이 떨어질 수 있습니다.

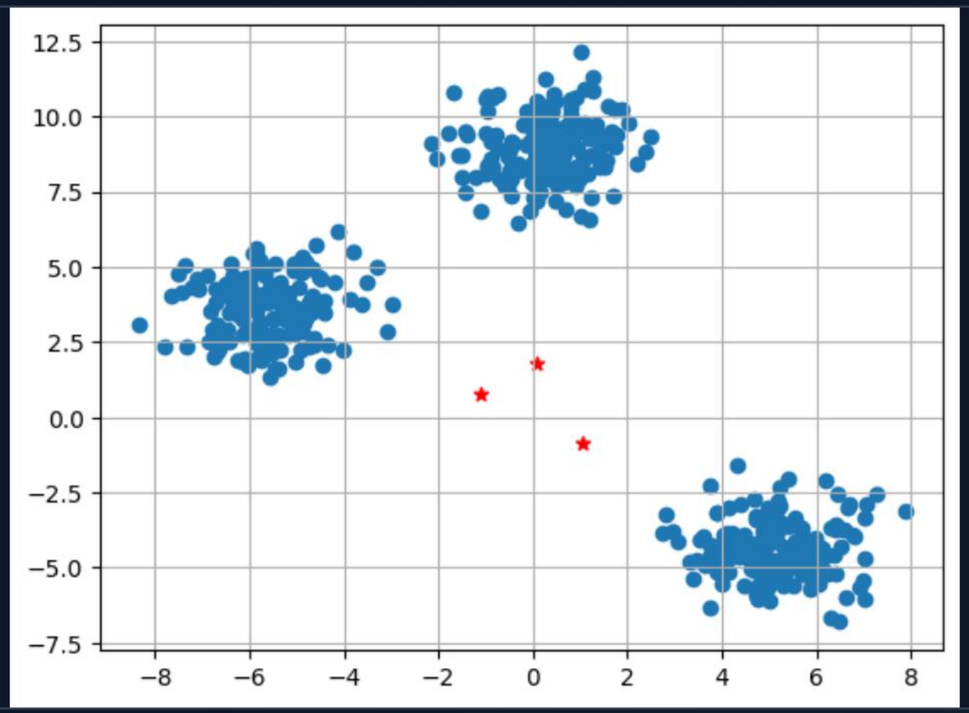

고급 군집화 모델

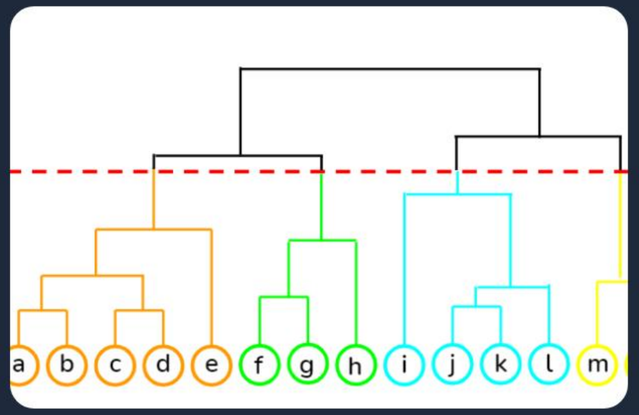

계층 클러스터링

AgglomerativeClustering

비슷한 데이터끼리 계층적으로 묶어 트리 구조(덴드로그램)를 만듭니다. 사전에 K를 정할 필요가 없습니다.

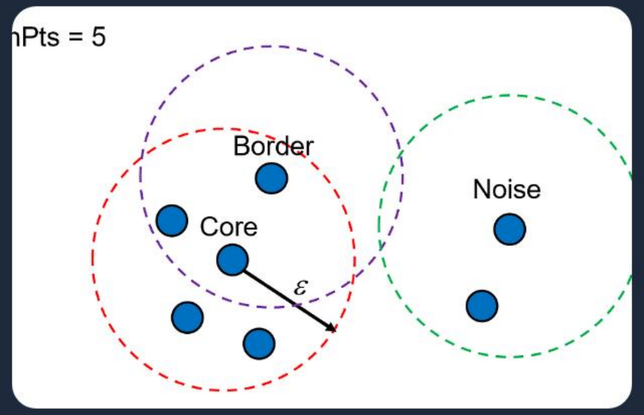

DBSCAN

DBSCAN

밀집된 곳을 하나의 그룹으로 묶고, 밀도가 낮은 곳은 노이즈로 처리합니다. 기하학적 모양의 군집 및 이상치 탐지에 매우 강합니다.

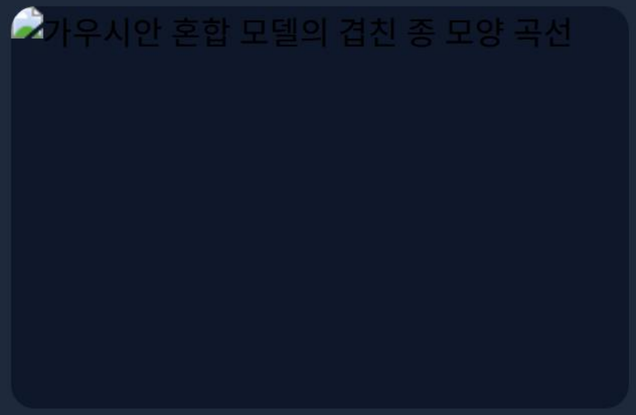

가우시안 혼합

GaussianMixture

데이터가 여러 개의 가우시안 분포(정규 분포)의 조합으로 생성되었다고 가정하고 확률적으로 군집을 나눕니다.

차원 축소 (Dimensionality Reduction)

핵심 정보를 유지하면서 데이터의 변수(특성) 개수를 줄여 시각화와 연산을 최적화합니다.

다양한 차원 축소 기법

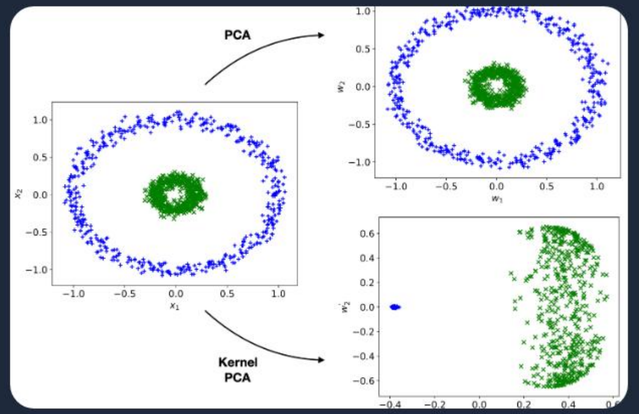

Kernel PCA

KernelPCA

데이터를 고차원 공간으로 매핑한 뒤 PCA를 수행하여, 비선형적인 패턴(휘어진 데이터)을 선형으로 펴서 축소합니다.

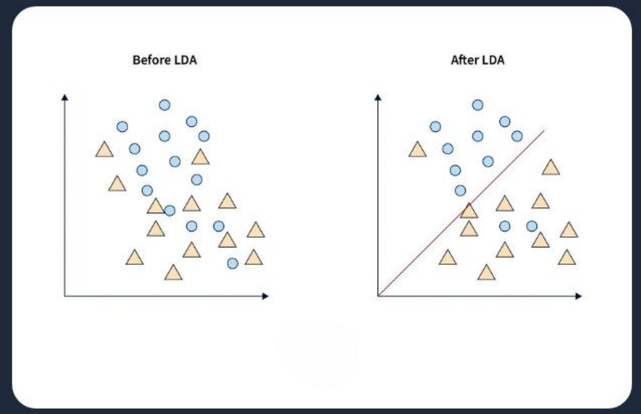

LDA

LinearDiscriminantAnalysis

클래스 간 분산은 최대화하고, 내부 분산은 최소화하는 축을 찾습니다. 지도 학습적 성격의 강력한 차원 축소법입니다.

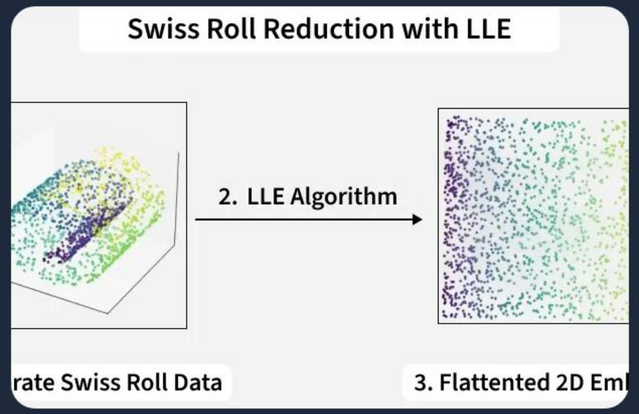

LLE

LocallyLinearEmbedding

포인트들 간의 국소적(가까운) 이웃 관계를 보존하며 축소합니다. 롤케이크처럼 말린 구조를 펼칠 때 탁월합니다.

Questions?

각 알고리즘의 세부 파라미터 튜닝 등에 대한 질의응답 시간입니다.

Image Sources

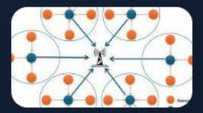

https://www.mdpi.com/sensors/sensors-25-01029/article_deploy/html/images/sensors-25-01029-g001-550.jpg

Source: www.mdpi.com

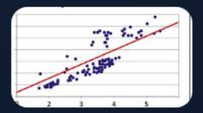

https://accmultimedia.austincc.edu/biocr/1406/labm/ex2/images/scatter_plot_sample.jpg

Source: accmultimedia.austincc.edu

---

https://global.discourse-cdn.com/dlai/optimized/3X/5/5/559728fe8ebac67a87c0d645840a3573b09c6568_2_690x394.jpeg

Source: community.deeplearning.ai

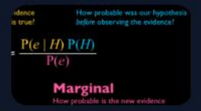

https://miro.medium.com/1*YTWinOBUgmStxkbUJZ1vNw.png

Source: medium.com

---

https://www.smartdraw.com/decision-tree/img/structure-of-a-decision-tree.png

Source: www.smartdraw.com

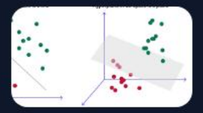

https://images.ctfassets.net/x78yjrjc11pq/45Q57eBLmYVXnX74k7QasA/a8e1186d6ab764676b1912addadfd628/Max__Hyperplanes.png

Source: www.tryexponent.com

Image Sources

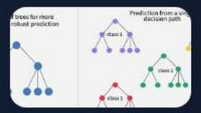

https://media.geeksforgeeks.org/wp-content/uploads/20250627112440591571/Random-Forest.webp

Source: www.geeksforgeeks.org

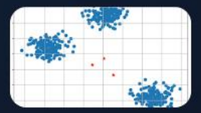

https://media.geeksforgeeks.org/wp-content/uploads/20230320172346/download-(27).png

Source: www.geeksforgeeks.org

---

https://towardsdatascience.com/wp-content/uploads/2021/05/1VvOVxdBb74IOxxF2RmthCQ.png

Source: towardsdatascience.com

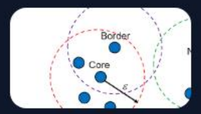

https://miro.medium.com/v2/resize:fit:1400/1*arv3b3Um_Opu_zOECGwt6w.png

Source: ai.plainenglish.io

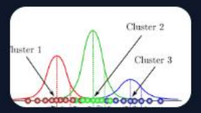

https://www.simplilearn.com/ice9/free_resources_article_thumb/Gaussian_Mixture_Models_%28GMM%29.png

Source: www.simplilearn.com

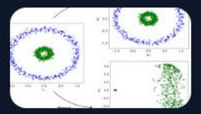

https://ml-lectures.org/_images/circles_pca_kpca.png

Source: ml-lectures.org

Image Sources

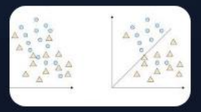

https://www.appliedaicourse.com/blog/wp-content/uploads/2024/10/Linear-Discriminant-Analysis-in-Machine-Learning.jpg

Source: www.appliedaicourse.com

---

https://media.geeksforgeeks.org/wp-content/uploads/20251110151345316875/swiss_roll_reduction_with_lle.webp

Source: www.geeksforgeeks.org